

K7 直播间短视频：数据预处理与分类验证报告

Yunxi

2026 年 4 月 21 日

1 背景与目标

本报告对应 `Week2_Task.md` 的交付要求 (Task3)。目标是基于已构建好的主表，对“爆款”与“非爆款”两组在核心绩效指标上的差异进行描述性统计与可视化，并给出对现有分类合理性的初步判断与疑问记录。

2 数据资产与口径说明

2.1 输入数据

- 主表: `Processed_Data/main_perf_merged_all.xlsx` (由任务二产出, 包含 `is_popular` 标签与 `source` 来源字段)。
- 图表文件: `Deliverables/week2_task3/figures/` (本报告插图直接引用该目录下 `png`)。

2.2 分组字段与样本规模

分组字段为 `is_popular` (0= 非爆款, 1= 爆款)。基于主表统计:

- 总样本量: 13856 条;
- 爆款: 1895 条 (13.68%);
- 非爆款: 11961 条 (86.32%)。

按数据来源 `source` 分层 (`dy/k7`) 统计如下:

source	非爆款	爆款
dy	10786	1752
k7	1175	143

3 数据清洗、对齐与整合方法 (任务一/二回顾)

本节描述了数据清洗、对齐、整合的具体过程与方法, 细节实现与过程记录见: `Analysis/Week2_Task1.ipynb`、`Analysis/Week2_Task2.ipynb`。

3.1 多源对齐与合并

- 对齐对象：K7 视频素材报表与金运抖音每日绩效数据。
- 对齐方式：以素材/视频的唯一标识（如素材 ID、文件名规范化后的匹配键）进行匹配；对每日绩效数据做多日合并，形成可按素材维度分析的主表。
- 合并策略：构建 `merged_common`（两批数据共有字段）与 `merged_all`（尽可能保留全量字段），并保留 `source` 以区分 dy/k7。

3.2 异常与缺失处理

- 缺失值：对关键指标列进行数值化与缺失处理（空值保留为 NA，在统计与绘图阶段按指标列 `dropna`）。
- 异常值：对“率”类指标中过大异常（例如 >100 ）样本进行过滤，以避免口径错误/抓取异常导致统计偏移（具体阈值与过滤实现见任务二 notebook）。
- 字段统一：对不同数据源同义字段进行统一命名（例如整体消耗/基础消耗归并、点击率/转化率字段统一）。

3.3 业务特征整合（可用属性）

- 时间特征：补充节假日、星期、月份等派生字段。
- 文本特征：对标题进行规范化；在可用情况下整合 LLM/embedding 等衍生字段（用于后续更深入的内容侧分析）。

4 爆款标签构建与验证策略

4.1 现有标签说明

任务二中为保证 dy 与 k7 两批素材使用统一口径，采用以下规则生成 `is_popular`：

- 以 消耗的箱线图上边界 ($Q3 + 1.5IQR$) 刻画“高流量/高投放”样本；
- 在高消耗样本中，要求 点击率或 转化率至少一个达到上四分位 ($Q3$)，以刻画“效率”；
- 满足上述条件则标为爆款，否则为非爆款。

4.2 验证原则

由于 `is_popular` 的生成直接使用了 消耗/点击率/转化率，因此这三个指标在两组上的差异属于规则内生，更适合作为口径解释而非验证证据。

因此本报告的分类验证优先查看未直接参与打标的指标：播放与互动、直播间行为、成交相关指标（可视作 GMV/订单代理指标）等。

5 描述性统计对比结果（附表）

表 1 给出部分关键验证指标的对比摘要（非爆款 vs 爆款）。其中：

- Median ratio 仅在非爆款中位数非 0 时可计算；
- 同时给出 Mean ratio 以反映长尾样本对均值的影响。

表 1: 关键验证指标：爆款 vs 非爆款

指标	Median(非爆款)	Median(爆款)	Median ratio	Mean ratio
展示次数	95	31126	327.642	15.442
播放数	74	31928	431.459	15.440
有效播放数	23	7193	312.739	19.417
点击次数	6	1459.5	243.250	12.666
转化数	0	37	—	24.594
直接成交金额	0	6373.6	—	24.803
直接支付 ROI	0	2.67	—	2.030
直播间观看人次	10	1581	158.100	11.968

初步观察：

- 在验证指标上，爆款组整体显著高于非爆款组（如播放、展示、成交金额、直播间观看等），说明现有分类与绩效表现大体一致；
- 多个指标的非爆款中位数为 0（例如成交金额、部分互动），说明数据整体呈现长尾分布，0 值较多。

6 可视化对比结果

下列图表均已保存至 `Deliverables/week2_task3/figures/`。




图 1: 成交表现-直接成交金额：爆款 vs 非爆款




图 2: 内容传播-播放数: 爆款 vs 非爆款




图 3: 直播间行为-直播间观看人次: 爆款 vs 非爆款

7 对现有分类合理性的初步思考与疑问

7.1 初步结论

- 从成交、播放、曝光、直播间行为等验证指标来看，爆款组显著优于非爆款组，现有分类与绩效表现总体相符。
- 由于爆款口径强调高消耗 + 点击率/转化率较高，当前标签更贴近投放/流量分配 + 转化效率的定义，未必等价于内容自然爆款（例如纯自然流量、互动驱动的爆款）。

7.2 疑问与下一步建议

- 分层验证：下一步会按照 `source` (dy/k7) 分别计算同一套对比，检查结论是否一致。当前已经统计过分层统计表，可进一步补充分层图表。
- 指标口径：若业务上更关注 GMV，可进一步确认直接成交金额/直接下单金额是否可作为 GMV 代理，以及是否需要合并其它 GMV 字段。
- 长尾与零值：现在统计结果发现多个指标存在大量 0 值与长尾，如果这些值想要保留，后续报告可以更侧重中位数/分位数，并在图表中采用对数尺度或截尾展示。




图 4: 口径解释-消耗 (规则内生指标)

- 内容侧解释: 后续的研究思路是, 把标题/标签/发布时间段等文本与时间特征纳入对比, 解释为什么爆款更爆, 而不仅是爆款更高。

8 复现方式与产出清单

- 复现: 运行 `Analysis/Week2_Task3.ipynb`。将自动在 `Deliverables/week2_task3/` 写出分析表、统计表与图表。
- 产出文件:
 - `Deliverables/week2_task3/K7 直播间短视频分析表.xlsx`
 - `Deliverables/week2_task3/task3_descriptive_stats.xlsx`
 - `Deliverables/week2_task3/figures/*.png`